

PiLp 学习笔记

这份笔记介绍 `import Mathlib.Analysis.Normed.Lp.PiLp`: 它为有限坐标族提供 L^p 风格的范数、距离、拓扑和常用定理。

```
import Mathlib.Analysis.Normed.Lp.PiLp
```

1. 模块概览

这个 `import` 引入的是 `mathlib` 中关于 有限乘积上的 L^p 距离 / 范数结构 的内容。

核心对象是:

`PiLp p α`

可以把 `PiLp p α` 理解成: 有限多个坐标组成的对象, 但 `Lean` 把它当成带有 L^p 范数和 L^p 距离的空间。

2. Pi 是什么?

`Pi` 不是英文缩写, 而是希腊字母 Π , 读作 *pi*。它在数学中表示“乘积”:

$$\prod_{i: \iota} \alpha_i$$

在类型论中, **Pi type** 指的是依赖乘积类型, 也叫依赖函数类型。

$$(i : \iota) \rightarrow \alpha_i$$

可以理解成:

$$\prod i : \iota, \alpha_i$$

意思是: 对每个 $i : \iota$, 给出一个属于 α_i 的值。

如果 α_i 不依赖于 i , 那么:

$$(i : \iota) \rightarrow \alpha$$

就退化成普通函数类型:

$$\iota \rightarrow \alpha$$

例如:

$$\text{Fin } 3 \rightarrow \mathbb{R}$$

可以看成三维实向量:

$$(x_0, x_1, x_2)$$

3. 有限类型是什么意思?

“若 ι 是有限类型”指的是: ι 这个指标类型里只有有限多个元素。

`Lean` 中通常写作:

$$[\text{Fintype } \iota]$$

意思是 `Lean` 知道 ι 可以被枚举完。

例如:

$$\text{Fin } 3$$

是有限类型， 里面有三个元素:

0, 1, 2

因此:

$\text{Fin } 3 \rightarrow \mathbb{R}$

可以理解成三维向量。

在 $\text{PiLp } p \ \alpha$ 中, ι 是坐标编号类型。若有 $[\text{Fintype } \iota]$, 就表示只有有限多个坐标, 因此可以使用有限求和。

$\sum i, \|x.\text{ofLp } i\|$

4. $\text{PiLp } p \ \alpha$ 是什么?

普通的 Pi 类型:

$(i : \iota) \rightarrow \alpha \ i$

只是“一组坐标”。

而:

$\text{PiLp } p \ \alpha$

是同样的一组坐标, 但 Lean 给它配上了 L^p 风格的范数和距离。

对象	理解
$(i : \iota) \rightarrow \alpha \ i$	普通坐标族
$\text{PiLp } p \ \alpha$	带有 L^p 范数 / 距离结构的坐标族

常用转换

`WithLp.toLp p f` -- 把普通函数放进 PiLp
`x.ofLp` -- 把 PiLp 元素取回普通函数
`x.ofLp i` -- 取第 i 个坐标

5. 有限乘积上的 L^p 范数

设:

$x = (x_i)_{i \in \iota}$

当 $1 \leq p < \infty$ 时:

$\|x\|_p = (\sum_i \|x_i\|^p)^{1/p}$

L^1 范数

$\|x\|_1 = \sum_i \|x_i\|$

所有坐标大小的总和。

L^2 范数

$\|x\|_2 = \sqrt{(\sum_i \|x_i\|^2)}$

欧几里得风格的范数。

L^∞ 范数

$\|x\|_\infty = \max_i \|x_i\|$

最大坐标范数。

L^0 “范数”

$$\|x\|_0 = \#\{i \mid x_i \neq 0\}$$

非零坐标的个数。严格说它不是范数。

6. L^p 距离

若:

$$x = (x_i)_{i \in I}, \quad y = (y_i)_{i \in I}$$

则:

$$d_p(x, y) = (\sum_i d(x_i, y_i)^p)^{1/p}$$

在实数向量中, 就是:

$$d_p(x, y) = (\sum_i |x_i - y_i|^p)^{1/p}$$

距离	公式	直觉
L^1	$d_1(x, y) = \sum_i d(x_i, y_i)$	曼哈顿距离
L^2	$d_2(x, y) = \sqrt{(\sum_i d(x_i, y_i)^2)}$	欧几里得距离
L^∞	$d_\infty(x, y) = \max_i d(x_i, y_i)$	最大坐标距离
L^0	$d_0(x, y) = \#\{i \mid x_i \neq y_i\}$	不同坐标的个数

7. L^0 与齐次性

L^0 范数和 L^0 距离要区分:

L^0 范数: 非零坐标的个数

L^0 距离: 两个向量不同坐标的个数

因为:

$$\|x\|_0 = d_0(x, 0)$$

L^0 严格来说不是范数, 因为它不满足范数的齐次性。

范数的齐次性要求:

$$\|a x\| = |a| \|x\|$$

但例如:

$$x = (1, 0, 2), \quad \|x\|_0 = 2$$

乘以 3 后:

$$3x = (3, 0, 6), \quad \|3x\|_0 = 2$$

而齐次性会要求:

$$\|3x\|_0 = 3\|x\|_0 = 6$$

这显然不成立。所以 L^0 常用于衡量稀疏性, 但不是严格意义的范数。

8. PiLp 中常用的定理

公共环境:

```

import Mathlib.Analysis.Normed.Lp.PiLp

open scoped BigOperators

variable {ι : Type*} [Fintype ι]
variable {β : ι → Type*}
variable [∀ i, SeminormedAddCommGroup (β i)]

```

常用结论包括:

```

PiLp.norm_eq_of_L1
PiLp.dist_eq_of_L1
PiLp.norm_eq_of_L2
PiLp.norm_sq_eq_of_L2
PiLp.dist_sq_eq_of_L2
PiLp.norm_apply_le
PiLp.dist_apply_le
PiLp.single
PiLp.norm_single
PiLp.ext
PiLp.continuous_apply

```

9. Lean 例子

展开 L^1 范数

```

example (x : PiLp 1 β) :
  ||x|| = ∑ i, ||x.ofLp i|| :=
  PiLp.norm_eq_of_L1 x

```

$$\|x\|_1 = \sum_i \|x_i\|$$

展开 L^1 距离

```

example (x y : PiLp 1 β) :
  dist x y = ∑ i, dist (x.ofLp i) (y.ofLp i) :=
  PiLp.dist_eq_of_L1 x y

```

$$d_1(x,y) = \sum_i d(x_i, y_i)$$

展开 L^2 范数平方

```

example (x : PiLp 2 β) :
  ||x|| ^ 2 = ∑ i, ||x.ofLp i|| ^ 2 :=
  PiLp.norm_sq_eq_of_L2 β x

```

$$\|x\|_2^2 = \sum_i \|x_i\|^2$$

展开 L^2 距离平方

```

example (x y : PiLp 2 β) :
  dist x y ^ 2 = ∑ i, dist (x.ofLp i) (y.ofLp i) ^ 2 :=
  PiLp.dist_sq_eq_of_L2 x y

```

$$d_2(x,y)^2 = \sum_i d(x_i, y_i)^2$$

坐标范数小于整体范数

```

example {p : ENNReal} [Fact (1 ≤ p)] (x : PiLp p β) (i : ι) :
  ||x.ofLp i|| ≤ ||x|| :=
  PiLp.norm_apply_le x i

```

$$\|x_i\| \leq \|x\|_p$$

本质原因是：非负求和中，单项不超过总和。

$$\|x_i\|^p \leq \sum_j \|x_j\|^p$$

坐标距离小于整体距离

```
example {p : ENNReal} [Fact (1 ≤ p)] (x y : PiLp p β) (i : ι) :
  dist (x.ofLp i) (y.ofLp i) ≤ dist x y :=
  PiLp.dist_apply_le x y i
```

$$d(x_i, y_i) \leq d_p(x, y)$$

这说明取某个坐标的投影映射是 1-Lipschitz 的。

构造单坐标向量

```
variable [DecidableEq ι]
```

```
example (p : ENNReal) (i : ι) (a : β i) :
  (PiLp.single p i a).ofLp i = a :=
  PiLp.single_eq_same p i a
```

$\text{PiLp.single } p \ i \ a$ 表示第 i 个坐标是 a ，其他坐标都是 0。

其他坐标为零

```
example (p : ENNReal) {i j : ι} (h : j ≠ i) (a : β i) :
  (PiLp.single p i a).ofLp j = 0 :=
  PiLp.single_eq_of_ne p h a
```

单坐标向量的范数

```
example {p : ENNReal} [Fact (1 ≤ p)] (i : ι) (a : β i) :
  ||PiLp.single p i a|| = ||a|| :=
  PiLp.norm_single p β i a
```

$$\|(0, \dots, a, \dots, 0)\|_p = \|a\|$$

用 **PiLp.ext** 逐坐标证明相等

```
example {p : ENNReal} {x y : PiLp p β}
  (h : ∀ i, x.ofLp i = y.ofLp i) :
  x = y :=
  PiLp.ext h
```

$$(\forall i, x_i = y_i) \Rightarrow x = y$$

10. 取坐标是连续函数

```
example (p : ENNReal) (i : ι) :
  Continuous fun x : PiLp p β => x.ofLp i :=
  PiLp.continuous_apply p β i
```

数学含义是：

$$x \mapsto x_i$$

是连续函数。

这最重要的用途是：整体收敛可以推出逐坐标收敛。

$$x_n \rightarrow x \Rightarrow x_n(i) \rightarrow x(i)$$

在 Lean 中，如果有：

$h : \text{Tendsto } u \text{ l } (\lambda x)$

其中:

$u : \gamma \rightarrow \text{PiLp } p \beta$

$x : \text{PiLp } p \beta$

那么可以得到第 i 个坐标也收敛:

$\text{Tendsto } (\text{fun } n \Rightarrow (u \ n).ofLp \ i) \text{ l } (\lambda (x.ofLp \ i))$

思路是使用:

$(\text{PiLp.continuous_apply } p \beta \ i).tendsto \ x$

和距离估计的关系

前面的定理:

$\text{PiLp.dist_apply_le}$

说的是:

$d(x_i, y_i) \leq d_p(x, y)$

这说明坐标投影是 1-Lipschitz 的, 而 1-Lipschitz 函数一定连续。

定理	含义
$\text{PiLp.dist_apply_le}$	更强的定量估计
$\text{PiLp.continuous_apply}$	由估计导出的拓扑结论

11. PiLp 和其他类似对象的区别

对象	用途
$\text{PiLp } p \alpha$	有限乘积上的 L^p 结构
$(i : \iota) \rightarrow \alpha \ i$	普通坐标族, 默认不一定是想要的 L^p 范数结构
l_p	可能无限指标集上的 L^p 空间, 需要考虑可和性、收敛性
MeasureTheory.Lp	测度空间上的 L^p 函数空间, 涉及几乎处处相等测度论内容

12. 总结

$\text{PiLp } p \alpha$ 可以理解成:

有限维向量或有限坐标族的 L^p 版本。

普通的:

$(i : \iota) \rightarrow \alpha \ i$

只是坐标族。而:

$\text{PiLp } p \alpha$

是同样的数据, 但配上了 L^p 范数、距离和拓扑结构。

最常用的直觉

L1: 坐标范数求和

L2: 平方和开根号

L^∞ : 最大坐标范数

L_0 : 非零坐标个数, 但严格来说不是范数

最常用的估计

$$\|x_i\| \leq \|x\|_p$$

$$d(x_i, y_i) \leq d_p(x, y)$$

最常用的拓扑结论

$$x_n \rightarrow x \implies x_n(i) \rightarrow x(i)$$

一句话:

整体收敛推出逐坐标收敛。

Mathlib.Analysis.Normed.Lp.PiLp 学习笔记 · HTML 展示版